遥感图像全色锐化与单幅图像去雨实验报告

DiCNN · FusionNet · DeRainNet

潘华熙　2024110902031

一、实验背景与目的

本次实验围绕遥感图像全色锐化（Pansharpening）与单幅图像去雨（Single Image Deraining）两项任务展开，共包含三个深度学习网络的搭建与训练：用于遥感图像融合的 DiCNN 和 FusionNet，以及用于自然图像去雨的 DeRainNet。

实验旨在通过完成这三个基于残差学习（Residual Learning）的模型实现、训练调优与定性定量评估，掌握“正向细节注入”（向低分辨率多光谱图像注入高频空间细节）与“逆向退化剥离”（从带雨图像中减去预测雨纹残差）的建模方法，深入理解卷积神经网络在图像融合与图像复原中的实际应用。

二、实验方法与数据

2.1 DiCNN 与 FusionNet（遥感全色锐化）

DiCNN 与 FusionNet 均采用基于全局残差跳连的细节注入框架：网络只学习缺失的高频空间细节，最后加回上采样多光谱图像 LMS 得到融合输出（Output = LMS + Detail），并采用 MSE（$\mathcal{L}_2$ Loss）进行监督训练。两者的核心差异在于输入构造方式与骨干特征提取深度：

- DiCNN（直接拼接 + 浅层卷积）：如图 1 所示，将 8 波段 LMS 与单波段 PAN 沿通道维直接拼接为 9 通道输入 [LMS, PAN]，依次经过 3 层 3×3 卷积（通道数 $9 \to 32 \to 32 \to 8$，前两层带 ReLU 激活）提取高频细节后加回 LMS。
- FusionNet（差分先验 + 残差块）：如图 2 所示，先将单通道 PAN 复制为 8 通道 PAN_{dup} 并与 LMS 相减，以高频差分 $\text{PAN}_{\text{dup}} - \text{LMS}$ 作为输入以提前滤除低频冗余；随后经过首层卷积（$8 \to 32$）、4 个串联的局部残差块（ResBlock，每个包含两层 3×3 卷积和块内跳连）以及输出层卷积（$32 \to 8$），最后同样加回 LMS。

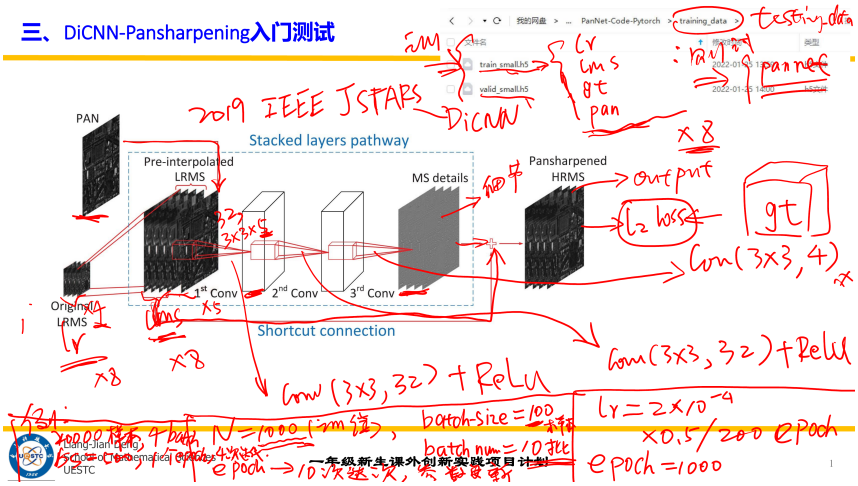


图 1: DiCNN 网络结构示意图。

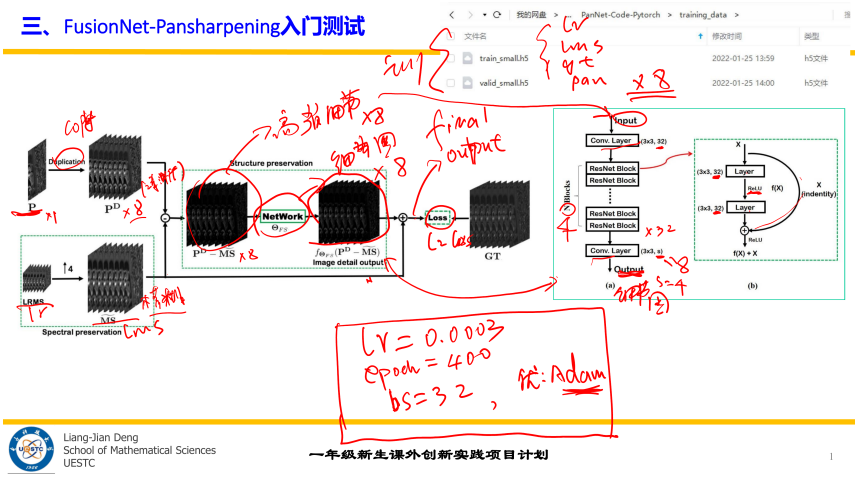


图 **2:** FusionNet 网络结构示意图。

2.2 DeRainNet（单幅图像去雨）

如图 3 所示，DeRainNet 采用三尺度并行残差结构预测雨纹层，再从输入带雨图像中减去雨纹得到去雨结果（Output = Input − Rain），训练损失采用对边缘保持更友好的 MAE（$\mathcal{L}_1$ Loss）：

1. 浅层特征与三尺度分支：输入图像（必要时边界补齐至 4 的倍数）先经首层 3×3 卷积（$3 \to 32$）和 LeakyReLU(0.01) 提取浅层特征，随后分为原尺度（1×）、1/2 下采样（`MaxPool2d(2)`）和 1/4 下采样（`MaxPool2d(4)`）三条并行分支。每条分支均由 8 个串联的 `ResBlock` 组成，并带有分支级外层跳连。
2. 上采样拼接与残差相减：1/2 与 1/4 分支输出通过双线性插值（`Upsample`）与两层 3×3 卷积恢复至原图尺寸，与原尺度分支沿通道拼接（$32 \times 3 = 96$ 通道），再经两层卷积（$96 \to 32 \to 3$）融合输出 3 通道预测雨纹，最后由输入图像减去预测雨纹完成复原。

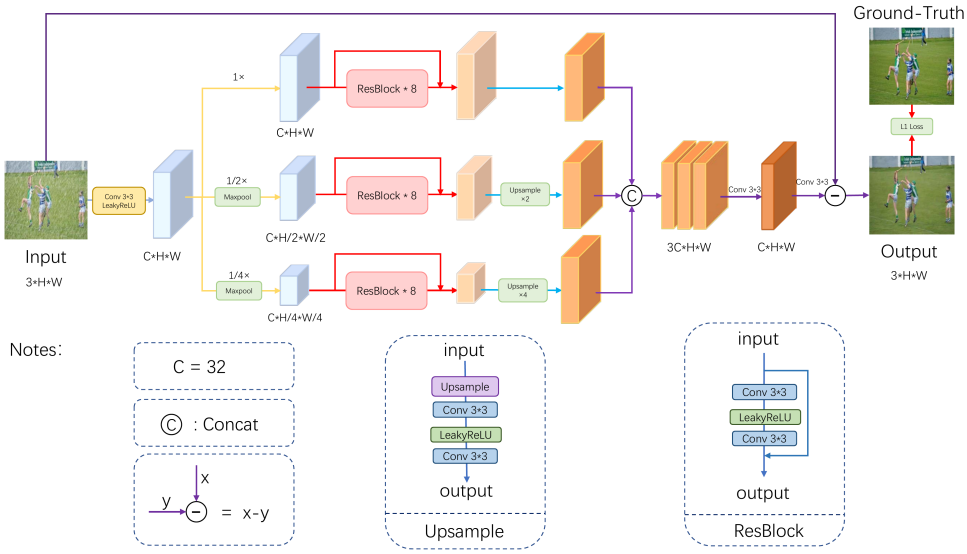


图 **3:** DeRainNet 多尺度残差去雨网络结构图。

2.3 数据集与预处理

实验所用数据集划分与核心预处理流程汇总如表 1 所示。WV3 遥感数据量化位深为 11-bit，训练前统一除以 `2047.0` 归一化至 $[0, 1]$，测试评估时乘回 `2047.0`；去雨测试集 `test12_chunks.mat` 读取后需通过 `permute(0, 3, 1, 2)` 由 `NHWC` 转为 PyTorch 标准 `NCHW` 格式。

实验任务	数据集划分与样本量	图像尺寸 ($H \times W$)	通道数	格式与关键预处理
遥感全色锐化 (WV3)	训练 1000 / 验证 80 / 测试 20	训练验证 64^2，测试 256^2	LMS/GT: 8, PAN: 1	`.h5` (NCHW)，除以 `2047.0` 归一化
单幅图像去雨	训练 1800 / 验证 200 / 测试 3	训练 64^2，验证 128^2，测试 320×480	RGB: 3	训练验证 `.h5` (NCHW)；测试 `.mat` 由 NHWC 转 NCHW

三、实验结果与分析

3.1 实验环境与超参数设置

实验基于 Apple M4（MPS 加速）与 PyTorch 2.13.0 完成，三个模型的超参数配置与最佳验证结果如表 2 所示。

配置项	DiCNN（全色锐化）	FusionNet（全色锐化）	DeRainNet（单幅图像去雨）
输入形式与参数量	[LMS, PAN] 拼接 / 14.2K	$\text{PAN}_{\text{dup}} - \text{LMS}$ 差分 / 78.6K	带雨 RGB 图像 / 510.3K
损失函数与优化器	MSE ($\mathcal{L}_2$) / Adam	MSE ($\mathcal{L}_2$) / Adam	MAE ($\mathcal{L}_1$) / Adam
初始学习率与调度	2×10^{-4} / `StepLR`(每 200 轮 $\times 0.5$)	3×10^{-4} / `StepLR`(每 200 轮 $\times 0.5$)	1×10^{-3} / `CosineAnnealingLR`
Batch Size / 总轮数	Batch = 100 / 1000 Epochs	Batch = 100 / 1000 Epochs	Batch = 16 / 60 Epochs
最佳验证集轮次	第 1000 轮 (MSE $= 7.14 \times 10^{-4}$)	第 990 轮 (MSE $= 4.68 \times 10^{-4}$)	第 53 轮 (MAE $= 9.99 \times 10^{-3}$)

3.2 遥感图像全色锐化结果分析（DiCNN vs. FusionNet）

(1) 训练收敛与定量指标对比

图 4 展示了 DiCNN 与 FusionNet 在 1000 轮训练中的 MSE 收敛曲线。两模型在前 100 轮均快速下降，并在每 200 轮学习率减半时呈现阶梯式收敛，训练集与验证集走势高度一致且无过拟合；其中 FusionNet 的最终验证 MSE（4.68×10^{-4}）比 DiCNN（7.14×10^{-4}）降低了 34.5%。

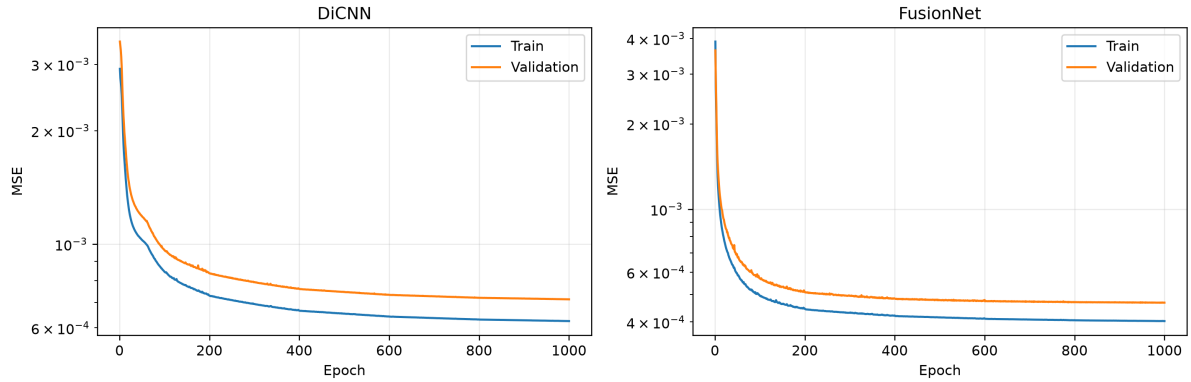


图 4: DiCNN 与 FusionNet 在 1000 轮训练中的训练集与验证集 MSE 收敛曲线。

在 20 张 256×256 的 WV3 测试集图像上，各方法的遥感五大指标与 PSNR/SSIM 评测结果如表 3 和图 5 所示。

对比方法	$Q2^n$ ($Q8$) ↑	Q_{avg} ↑	SAM (°) ↓	ERGAS ↓	SCC ↑	PSNR (dB) ↑	SSIM ↑
LMS（上采样基线）	0.6270 ± 0.0923	0.6317 ± 0.1018	5.8001 ± 1.8811	7.1555 ± 1.8775	0.7440 ± 0.0288	27.12 ± 2.55	0.7224 ± 0.0980
DiCNN（DLPan 参考）	0.7937 ± 0.0900	0.8257 ± 0.0885	5.0793 ± 1.3333	4.9769 ± 1.0665	0.9292 ± 0.0153	30.17 ± 3.17	0.8991 ± 0.0280
FusionNet（DLPan 参考）	0.8195 ± 0.0804	0.8252 ± 0.0901	4.8972 ± 1.2741	4.7239 ± 1.0741	0.9204 ± 0.0073	30.66 ± 2.72	0.8955 ± 0.0337
DiCNN（本实验训练）	0.8543 ± 0.1071	0.8708 ± 0.1033	4.7468 ± 1.2035	3.4901 ± 0.9993	0.9538 ± 0.0178	33.55 ± 1.35	0.9394 ± 0.0170
FusionNet（本实验训练）	0.8923 ± 0.0930	0.8988 ± 0.0952	3.7567 ± 0.8192	2.8078 ± 0.6959	0.9724 ± 0.0085	35.25 ± 1.63	0.9613 ± 0.0104

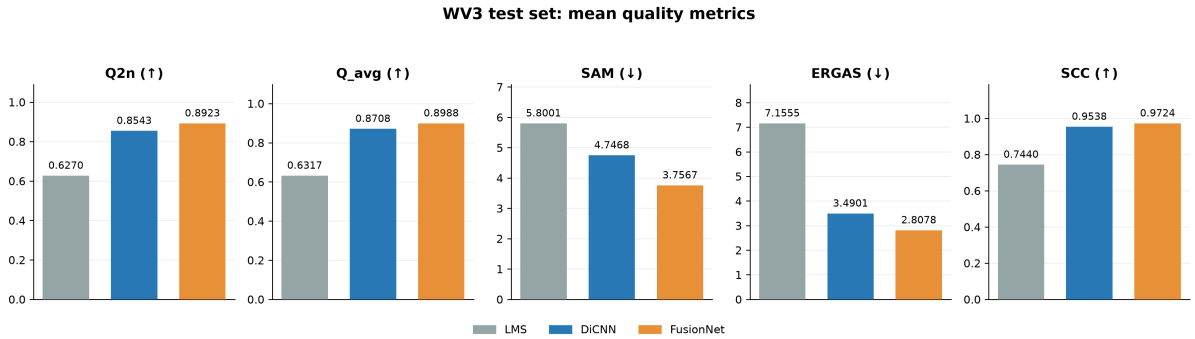


图 5: WV3 测试集上 LMS 基线、DiCNN 与 FusionNet 的五项遥感指标对比图。

核心结果分析：

1. 残差细节注入效果显著：相比模糊的 LMS 基线，本实验训练的 DiCNN 与 FusionNet 均实现了大幅提升，PSNR 分别提高 6.43 dB 和 8.13 dB，且显著优于预训练参考基线。
2. FusionNet 全面优于 DiCNN 的原因：FusionNet 在所有指标上均取得最优（$Q2^n$ 达 0.8923、SAM 降至 3.76°、ERGAS 降至 2.81、PSNR 高出 DiCNN 1.70 dB）。一方面，FusionNet 在输入端直接构造 $\mathrm{PAN}_{\mathrm{dup}} - \mathrm{LMS}$ 差分，提前消除了低频背景干扰，使网络专注于高频边缘调制与光谱修正；另一方面，4 个串联 `ResBlock` 比 DiCNN 的 3 层平铺卷积具有更大的感受野和更强的非线性拟合能力。

（2）视觉对比与误差热力图分析

图 6 展示了测试集海岸建筑场景的伪彩色合成图与全波段平均绝对误差热力图（颜色越暗表示与 GT 误差越小）。可以看到，DiCNN 和 FusionNet 均有效恢复了 LMS 中模糊的房屋轮廓与海面船只细节；而在下排热力图中，DiCNN 在高反射屋顶边缘仍有少量橙色残差，FusionNet 的误差热力图则整体呈深暗紫色，在高频建筑边缘和背景区域均展现出更高的重建精度。

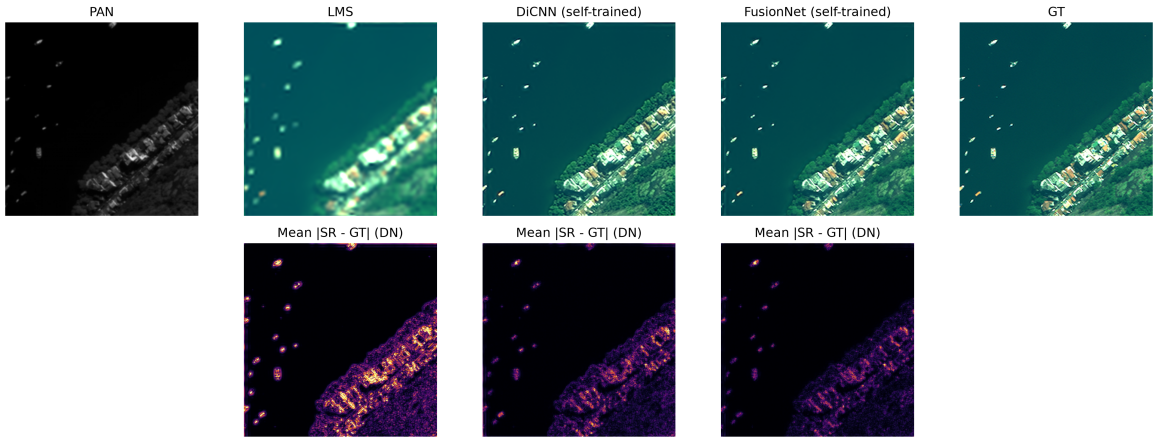


图 6: WV3 测试样本伪彩色视觉对比（上排）与全波段平均绝对误差热力图（下排）。

3.3 单幅图像去雨结果分析（DeRainNet）

（1）训练曲线与消融对比

图 7 为 DeRainNet 在 60 轮训练中的 $\mathcal{L}_1$ 损失及 PSNR/SSIM 变化曲线。前 20 轮网络快速剥离主要雨纹，验证集 PSNR 从 25.40 dB 跃升至 31 dB 以上；随后在余弦退火调度下平稳收敛，于第 53 轮取得最佳验证性能（PSNR 33.01 dB，SSIM 0.9579）。

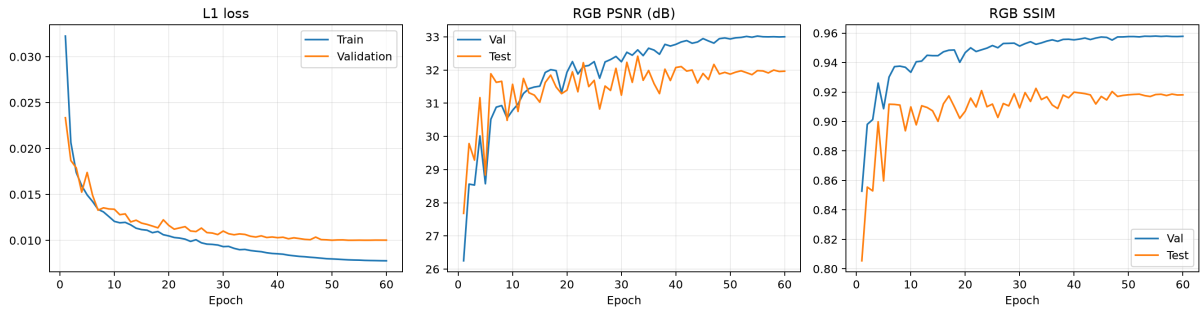


图 7: DeRainNet 在 60 轮训练过程中的 L1 损失（左）以及验证集/测试集 PSNR（中）、SSIM（右）曲线。

此外，我们在 25 轮固定种子设置下对比了不同 LeakyReLU 负半轴斜率与数据增强策略（表 4）。结果显示 $\alpha = 0.01$ 的 Baseline 配置表现最优（测试集 PSNR 31.21 dB，高于 $\alpha = 0.2$ 的 30.93 dB），说明较小的负斜率既能避免梯度归零，又能保持更好的稀疏雨纹特征选择能力。

消融实验配置 (25 Epochs)	验证集 PSNR ↑	验证集 SSIM ↑	验证集 L1 ↓	测试集 PSNR ↑	测试集 SSIM ↑	测试集 L1 ↓
Baseline ($\alpha = 0.01$)	30.68 dB	0.9341	0.0136	31.21 dB	0.9018	0.0148
Variant A ($\alpha = 0.2$)	30.49 dB	0.9316	0.0138	30.93 dB	0.8946	0.0154
Variant B ($\alpha = 0.2$ + 水平翻转)	30.54 dB	0.9323	0.0137	30.94 dB	0.8947	0.0154

（2）验证集与测试集去雨前后定量对比

利用第 53 轮最优模型在验证集（200 张）与测试集（3 张）上进行去雨前后对比，结果如表 5 所示。

评估对象（RGB 通道）	去雨前 PSNR	去雨后 PSNR	PSNR 提升 (Δ)	去雨前 SSIM	去雨后 SSIM	SSIM 提升 (Δ)	去雨前 MAE	去雨后 MAE
验证集均值 (200 张)	25.40 dB	33.01 dB	+7.61 dB	0.8427	0.9579	+0.1152	0.0228	0.0100
测试图 1（石拱门与砖墙）	27.15 dB	32.75 dB	+5.60 dB	0.7655	0.9151	+0.1496	0.0235	0.0118
测试图 2（传统船形屋顶）	27.04 dB	32.76 dB	+5.72 dB	0.7882	0.9326	+0.1444	0.0213	0.0109
测试图 3（树洞中的山猫）	26.01 dB	30.26 dB	+4.25 dB	0.8179	0.9049	+0.0870	0.0258	0.0162
测试集均值 (3 张)	26.74 dB	31.92 dB	+5.18 dB	0.7905	0.9176	+0.1271	0.0235	0.0130

定量分析：DeRainNet 在验证集上实现了 +7.61 dB 的 PSNR 提升与 56.1% 的 MAE 降幅；在 3 张测试图上平均 PSNR 提升 +5.18 dB（达 31.92 dB），平均 SSIM 提升 +0.1271（达 0.9176）。其中测试图 1、2 的增益均超过 5.6 dB，而测试图 3 增益相对较低（+4.25 dB），原因是图 3 中密集的山猫毛发、胡须及植物纹理与细雨纹在高频频谱上存在较强混叠。

（3）去雨视觉效果与细节恢复分析

图 8～图 10 展示了 3 张测试图的去雨效果对比，图 11 与图 12 进一步展示了预测雨纹残差图与中心区域（120 × 160）局部放大对比。可以看到：

- 多尺度雨纹剥离干净：无论是暗部水面的高亮细雨丝还是天空中的宽幅雨带均被彻底清除，图 11 第三列提取出的雨纹残差图极为纯粹，几乎未混入背景建筑轮廓；
- 高频背景纹理保留完好：从图 12 局部放大图可见，去雨后的木栏杆边缘、船形屋檐雕刻以及山猫眼部高光与细密胡须均清晰锐利，未出现明显涂抹模糊，验证了三尺度并行残差金字塔与 $\mathcal{L}_1$ 损失的有效性。



图 **8:** 测试图 1 去雨前后对比（左：带雨输入，中：DeRainNet 输出，右：GT）。



图 **9:** 测试图 2 去雨前后对比（左：带雨输入，中：DeRainNet 输出，右：GT）。



图 **10:** 测试图 3 去雨前后对比（左：带雨输入，中：DeRainNet 输出，右：GT）。

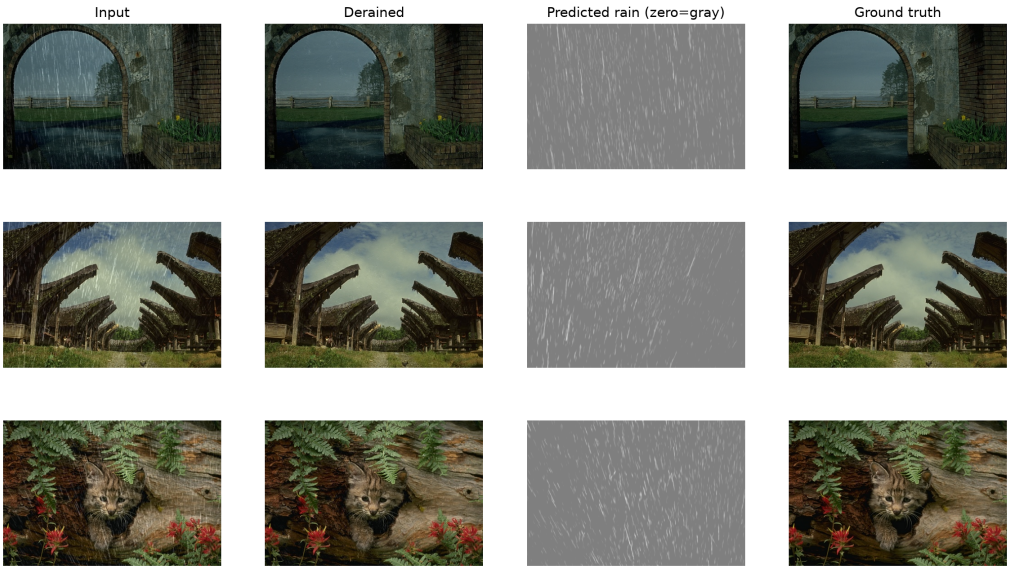


图 **11:** 3 张测试图像的去雨过程分解（从左至右：带雨输入、去雨输出、预测雨纹残差层、GT）。



图 12: 3 张测试图像中心区域（120 × 160）局部放大对比（左：带雨输入，中：去雨输出，右：GT）。

四、总结

通过完成 DiCNN、FusionNet 与 DeRainNet 三个实验，我们直观体会到残差学习在底层视觉任务中的核心作用：无论是全色锐化中的正向细节注入（LMS+Detail），还是图像去雨中的逆向退化剥离（Input−Rain），跨层跳连都将网络的学习目标集中在稀疏高频残差上，显著降低了收敛难度并保证了全局色彩与辐射基调的稳定。

同时，实验结果清晰地验证了网络结构设计的演进规律：在全色锐化任务中，FusionNet 借助输入端物理差分先验（$\mathrm{PAN}_{\mathrm{dup}} - \mathrm{LMS}$）与深层 `ResBlock`，相比直接拼接的 DiCNN 将测试集 PSNR 从 33.55 dB 提升至 35.25 dB、光谱角误差 SAM 从 4.75° 降至 3.76°；在图像去雨任务中，DeRainNet 通过 $1\times$、$1/2\times$、$1/4\times$ 三尺度并行残差分支有效兼顾了不同粗细雨纹的剥离与背景细节保护，在测试集上实现了 +5.18 dB 的平均 PSNR 提升。